Параллельные коллекции

Введение	2
IProducerConsumerCollection <t></t>	3
ConcurrentBag <t></t>	5
BlockingCollection <t></t>	6
Реализация очереди производителей/потребителей	8

Введение

В версии .NET Framework 4.0 появился набор новых коллекций, определенных в пространстве имен System.Collections.Concurrent. Все они полностью безопасны в отношении потоков:

Табл. Параллельные коллекции

Параллельная коллекция	Непараллельный эквивалент
ConcurrentStack <t></t>	Stack <t></t>
ConcurrentQueue <t></t>	Queue <t></t>
ConcurrentBag <t></t>	(отсутствует)
ConcurrentDictionary <tkey, tvalue=""></tkey,>	Dictionary <tkey, tvalue=""></tkey,>

Параллельные коллекции оптимизированы для сценариев с высокой степенью параллелизма; тем не менее, они также могут быть полезны в ситуациях, когда требуется коллекция, безопасная к потокам (в качестве альтернативы применению блокировки к обычной коллекции). Однако с параллельными коллекциями связано несколько важных предостережений:

- По производительности традиционные коллекции превосходят параллельные коллекции во всех сценариях кроме тех, которые характеризуются высокой степенью параллелизма.
- Безопасная к потокам коллекция вовсе не гарантирует, что код, в котором она используется, будет безопасным в отношении потоков.
- Если вы производите перечисление параллельной коллекции, в то время как другой поток ее модифицирует, то никаких исключений не возникает взамен вы получите смесь старого и нового содержимого.
- Параллельной версии List < T > не существует.
- Параллельные классы стека, очереди и пакета внутренне реализованы с помощью связных списков. Это делает их менее эффективными в плане потребления памяти, чем непараллельные классы Stack и Queue, но лучшими для параллельного доступа, т.к. связные списки способствуют построению реализаций с низкой

блокировкой или вообще без таковой. (Причина в том, что вставка узла в связный список требует обновления лишь пары ссылок, тогда как вставка элемента в структуру, подобную List< T>, может привести к перемещению тысяч существующих элементов.)

Другими словами, параллельные коллекции не являются простыми сокращениями для применения обычных коллекций с блокировками.

Параллельные коллекции также отличаются от традиционных коллекций тем, что они открывают доступ к специальным методам, которые предназначены для выполнения атомарных операций типа "проверить и действовать", подобных TryPop. Большинство таких методов унифицировано посредством интерфейса IProducerConsumerCollection < T >.

IProducerConsumerCollection<T>

Коллекция производителей/потребителей является одной из тех, для которых предусмотрены два главных сценария использования:

- добавление элемента (действие "производителя");
- извлечение элемента с его удалением (действие "потребителя").

Классическими примерами являются стеки и очереди. Коллекции производителей/потребителей играют важную роль в параллельном программировании, т.к. они способствуют построению эффективных реализаций, свободных от блокировок.

Интерфейс *IProducerConsumerCollection<T>* представляет безопасную к потокам коллекцию производителей/потребителей и реализован следующими классами:

- ConcurrentStack<T>
- ConcurrentQueue<T>
- ConcurrentBag<T>

Интерфейс IProducerConsumerCollection<Т> расширяет ICollection,

добавляя перечисленные ниже методы:

```
void CopyTo(T[] array, int index);
T[] ToArray();
bool TryAdd(T item);
bool TryTake(out T item);
```

Методы *TryAdd* и *TryTake* проверяют, может ли быть выполнена операция добавления/удаления, и если может, тогда производят добавление/удаление. Проверка и действие выполняются атомарно, устраняя необходимость в блокировке, к которой пришлось бы прибегнуть в случае традиционной коллекции:

```
int result;
lock (myStack) if (myStack.Count > 0) result = myStack.Pop();
```

Метод *TryTake* возвращает *false*, если коллекция пуста. Метод *TryAdd* всегда выполняется успешно и возвращает *true* в предоставленных трех реализациях. Однако если вы разрабатываете собственную параллельную коллекцию, в которой дубликаты запрещены, то обеспечите возврат методом *TryAdd* значения *false*, когда заданный элемент уже существует (примером может служить реализация параллельного набора).

Конкретный элемент, который *TryTake* удаляет, определяется подклассом:

- в случае стека *TryTake* удаляет элемент, добавленный позже всех других;
- в случае очереди *TryTake* удаляет элемент, добавленный раньше всех других;
- в случае пакета *TryTake* удаляет любой элемент, который может быть удален наиболее эффективно.

Три конкретных класса главным образом реализуют методы TryTake и TryAdd явно, делая доступной ту же самую функциональность через открытые методы с более специфичными именами, такими как TryDequeue и TryPop.

ConcurrentBag<T>

Класс ConcurrentBag < T > хранит неупорядоченную коллекцию объектов (с разрешенными дубликатами). Класс <math>ConcurrentBag < T > подходит в ситуациях, когда не имеет значения, какой элемент будет получен при вызове <math>Take или TryTake.

Преимущество ConcurrentBag < T > перед параллельной очередью или стеком связано с тем, что метод Add пакета не допускает почти состязаний, когда вызывается никаких одновременно. В отличие от него вызов Add параллельно на очереди или стеке приводит к некоторым состязаниям (хотя и при блокировании намного меньшим, чем непараллельной коллекции). Вызов *Take* на параллельном пакете также очень эффективен – до тех пор, пока каждый поток не извлекает большее количество элементов, чем он добавил с помощью Add.

Внутри параллельного пакета каждый поток получает свой закрытый связный список. Элементы добавляются в закрытый список, который принадлежит потоку, вызывающему Add, что устраняет состязания. Когда производится перечисление пакета, перечислитель проходит по закрытым спискам всех потоков, выдавая каждый из их элементов по очереди. Когда вызывается метод Take, пакет сначала просматривает закрытый список текущего потока. Если в нем имеется хотя бы один элемент, то задача может быть завершена легко и без состязаний. Но если этот список пуст, то пакет должен "позаимствовать" элемент из закрытого списка другого потока, что потенциально может привести к состязаниям.

Таким образом, чтобы соблюсти точность, вызов *Take* дает элемент, который был добавлен позже других в данном потоке; если в этом потоке элементов нет, тогда *Take* дает последний добавленный элемент в другом потоке, выбранном произвольно.

Параллельные пакеты идеальны, когда параллельная операция на коллекции в основном состоит из добавления элементов посредством Add — или когда количество вызовов Add и Take сбалансировано в рамках потока. Пример первой ситуации приводился ранее во время применения метода Parallel.ForEach при реализации параллельной программы проверки орфографии:

```
var misspellings = new ConcurrentBag<Tuple<int, string>>();
Parallel.ForEach(wordsToTest, (word, state, i) =>
{
  if (!wordLookup.Contains(word))
    misspellings.Add(Tuple.Create((int)i, word));
});
```

Параллельный пакет может оказаться неудачным выбором для очереди производителей/потребителей, поскольку элементы добавляются и удаляются разными потоками.

BlockingCollection<T>

В случае вызова метода *TryTake* на любой коллекции производителей/потребителей, рассмотренной ранее:

ConcurrentStack<T>, ConcurrentQueue<T>, ConcurrentBag<T>, он возвращает false, если коллекция пуста. Иногда в таком сценарии полезнее организовать ожидание, пока элемент не станет доступным. Вместо перегрузки методов TryTake для такой функциональности привело (что перенасыщению членами после предоставления возможности работы с признаками отмены и тайм-аутами) проектировщики РҒХ класс-оболочку инкапсулировали ee В ПО имени BlockingCollection<Т>. Блокирующая коллекция может содержать любую коллекцию, которая реализует IProducerConsumerCollection<T>, и позволяет получать с помощью метода Take элемент из внутренней коллекции, обеспечивая блокирование, когда доступных элементов нет.

Блокирующая коллекция также позволяет ограничивать общий размер коллекции, блокируя производителя, если этот размер

превышен. Коллекция, ограниченная в подобной манере, называется ограниченной блокирующей коллекцией.

Для использования класса *BlockingCollection<T>* необходимо выполнить описанные ниже шаги.

- 1. Создать экземпляр класса, дополнительно указывая помещаемую внутрь реализацию IProducerConsumerCollection < T > и максимальный размер (границу) коллекции.
- 2. Вызывать метод *Add* или *TryAdd* для добавления элементов во внутреннюю коллекцию.
- 3. Вызывать метод *Take* или *TryTake* для удаления (потребления) элементов из внутренней коллекции.

Если конструктор вызван без передачи ему коллекции, то автоматически будет создан экземпляр ConcurrentQueue<T>. Методы производителя и потребителя позволяют указывать признаки отмены и тайм-ауты. Методы Add и TryAdd могут блокироваться, если размер коллекции ограничен; методы Take и TryTake блокируются на время, пока коллекция пуста.

Еще один способ потребления элементов предполагает вызов метода GetConsumingEnumerable. Он возвращает (потенциально) бесконечную последовательность, которая выдает элементы по мере того, как они становятся доступными. Чтобы принудительно завершить такую последовательность, необходимо вызвать CompleteAdding: этот метод также предотвращает помещение в очередь дальнейших элементов.

Кроме того, класс *BlockingCollection* предоставляет статические методы под названиями *AddToAny* и *TakeFromAny*, которые позволяют добавлять и получать элемент, указывая несколько блокирующих коллекций. Действие затем будет выполнено первой коллекцией, которая способна обслужить данный запрос.

Реализация очереди производителей/потребителей

Очередь производителей/потребителей – структура, полезная как при параллельном программировании, так и в общих сценариях параллелизма. Основные аспекты ее работы:

- Очередь настраивается для описания элементов работы или данных, над которыми выполняется работа.
- Когда задача должна выполниться, она ставится в очередь, а вызывающий код занимается другой работой.
- Один или большее число рабочих потоков функционируют в фоновом режиме, извлекая и запуская элементы из очереди.

Очередь производителей/потребителей обеспечивает контроль над тем, сколько рабочих потоков выполняется за раз, что полезно для ограничения эксплуатации не только ЦП, но также и других ресурсов. Скажем, если задачи выполняют интенсивные ввода-вывода, операции дискового TO можно ограничить параллелизм, не истощая операционную систему приложения. На протяжении времени жизни очереди можно также динамически добавлять и удалять рабочие потоки. Пул потоков CLR сам представляет собой разновидность производителей/потребителей, которая оптимизирована для кратко выполняющихся заданий с интенсивными вычислениями.

Очередь производителей/потребителей обычно хранит элементы данных, на которых выполняется (одна и та же) задача. Например, элементами данных могут быть имена файлов, а задача может осуществлять шифрование содержимого таких файлов. С другой стороны, применяя делегаты в качестве элементов, можно построить более универсальную очередь производителей/потребителей, где каждый элемент способен делать все что угодно.

В статье "Parallel Programming" ("Параллельное программирование") по адресу http://albahari.com/threading показано, как реализовать очередь производителей/потребителей

с нуля, используя событие AutoResetEvent (а также впоследствии методы Wait и Pulse класса Monitor). Тем не менее, начиная с версии .NET Framework 4.0, написание очереди производителей/потребителей с нуля стало необязательным, т.к. большая часть функциональности предлагается классом BlockingCollection < T >. Вот как его задействовать:

```
public class PCQueue : IDisposable
 BlockingCollection<Action> taskQ = new BlockingCollection<Action>();
 public PCQueue(int workerCount)
    // Создать и запустить отдельный объект Task
   // для каждого потребителя:
   for (int i = 0; i < workerCount; i++)</pre>
     Task.Factory.StartNew(Consume);
 public void Enqueue(Action action) { taskQ.Add(action); }
 void Consume()
    // Эта перечисляемая последовательность будет блокироваться
    // когда нет доступных элементов, и заканчиваться, когда вызван
   // метод CompleteAdding.
   foreach (Action action in _taskQ.GetConsumingEnumerable())
                 // Выполнить задачу.
     action();
 public void Dispose() {  taskQ.CompleteAdding(); }
```

Поскольку конструктору *BlockingCollection* ничего не передается, он автоматически создает параллельную очередь. Если бы ему был передан объект *ConcurrentStack*, тогда мы получили бы в итоге стек производителей/потребителей.

Использование задач

Только что написанная очередь производителей/потребителей не является гибкой, т.к. мы не можем отслеживать элементы работы после их помещения в очередь. Очень полезными были бы следующие возможности:

- знать, когда элемент работы завершается (и ожидать его посредством await);
- отменять элемент работы;
- элегантно обрабатывать любые исключения, которые сгенерированы тем или иным элементом работы.

Идеальное решение предусматривало бы возможность возвращения методом Enqueue какого-то объекта, снабжающего нас описанной выше функциональностью. К счастью, уже существует класс, делающий в точности то, что нам нужно – это Task, объект которого можно либо сгенерировать с помощью TaskCompletionSource, либо создать напрямую (получив незапущенную или холодную задачу):

```
public class PCQueue : IDisposable
 BlockingCollection<Task> taskQ = new BlockingCollection<Task>();
 public PCQueue(int workerCount)
    // Создать и запустить отдельный объект Task
   // для каждого потребителя:
   for (int i = 0; i < workerCount; i++)</pre>
     Task.Factory.StartNew(Consume);
 public Task Enqueue(Action action, CancellationToken cancelToken =
default(CancellationToken))
   var task = new Task(action, cancelToken);
    _taskQ.Add(task);
   return task;
 public Task<TResult> Enqueue<TResult>(Func<TResult> func,
     CancellationToken cancelToken = default(CancellationToken))
   var task = new Task<TResult>(func, cancelToken);
    taskQ.Add(task);
   return task;
```

```
void Consume()
{
  foreach (var task in _taskQ.GetConsumingEnumerable())
    try
    {
     if (!task.IsCanceled) task.RunSynchronously();
    }
    catch (InvalidOperationException) { } // Условие состязаний
}
public void Dispose() { _taskQ.CompleteAdding(); }
}
```

В методе *Enqueue* мы помещаем в очередь и возвращаем вызывающему коду задачу, которая создана, но не запущена.

В методе *Consume* мы запускаем эту задачу синхронно в потоке потребителя. Мы перехватываем исключение *InvalidOperationException*, чтобы обработать маловероятную ситуацию, когда задача будет отменена в промежутке между проверкой, не отменена ли она, и ее запуском.

Ниже показано, как можно применять класс *PCQueue*:

```
// Максимальная степень параллелизма равна 2
var pcQ = new PCQueue(2);
string result = await pcQ.Enqueue(() => "That was easy!");
```

Следовательно, мы имеем все преимущества задач – распространение исключений, возвращаемые значения и возможность отмены – и в то же время обладаем полным контролем над их планированием.